CANCERCARE AI - WEBSITE

https://cancercare-ai.streamlit.app

WHY CANCER?

Kanker merupakan salah satu penyakit paling mematikan di dunia yang telah merenggut jutaan nyawa setiap tahunnya. Tingkat kematian yang tinggi dan penyebaran sel kanker yang cepat membuatnya menjadi ancaman serius bagi kesehatan global. Deteksi dini sangat penting untuk meningkatkan peluang kesembuhan, namun proses diagnosis kanker seringkali membutuhkan waktu, biaya besar, dan keahlian medis yang mendalam. Oleh karena itu melalui CancerCare AI, proyek ini hadir untuk menjawab kebutuhan deteksi awal dengan pendekatan berbasis kecerdasan buatan. Dengan memanfaatkan machine learning dan data medis, CancerCare AI mampu mengidentifikasi jenis kanker dari teks deskriptif medis, seperti kanker paru-paru, kolon, dan tiroid.. Proyek ini bertujuan untuk mendukung upaya tersebut dengan membangun model klasifikasi teks yang mampu mengenali jenis kanker seperti kanker paru-paru, kolon, dan tiroid secara otomatis, cepat, dan efisien.

https://cancercare-ai.streamlit.app

TUJUAN

MENDETEKSI JENIS KANKER DARI TEKS MEDIS

Mengembangkan model machine learning yang mampu mengidentifikasi dan mengklasifikasikan jenis kanker seperti kanker paru-paru, kolon, dan tiroid berdasarkan input teks deskriptif medis.

MENYEDERHANAKAN ANALISIS DATA KLINIS

Mengubah teks klinis yang kompleks menjadi informasi terstruktur dan mudah dipahami, sehingga mempermudah analisis dan pengambilan keputusan.

MEMPERCEPAT PROSES DIAGNOSIS AWAL

Memberikan dukungan kepada tenaga medis melalui prediksi otomatis yang cepat dan efisien, sehingga potensi keterlambatan diagnosis dapat diminimalisir.

MENINGKATKAN AKSESIBILITAS TEKNOLOGI KESEHATAN

Membuat solusi berbasis AI yang ringan dan mudah digunakan, sehingga bisa dimanfaatkan oleh fasilitas kesehatan dengan sumber daya terbatas.

https://cancercare-ai.streamlit.app

WORKFLOW

Representing Data

Exploratory Data Analysis (EDA)

Preprocessing

Model Development & Evaluation

Custom Prediction

Save Model

https://cancercare-ai.streamlit.app

REPRESENTING DATA

FALGUNIPATEL19 · UPDATED 3 YEARS AGO 72 Code Download

Medical Text Dataset - Cancer Doc Classification

Cancer Text Documents Classification

	Target	Text
0	Thyroid_Cancer	Thyroid surgery in children in a single insti...
1	Thyroid_Cancer	" The adopted strategy was the same as that us...
2	Thyroid_Cancer	coronary arterybypass grafting thrombosis ï¬b...
3	Thyroid_Cancer	Solitary plasmacytoma SP of the skull is an u...
4	Thyroid_Cancer	This study aimed to investigate serum matrix ...

Dataset ini berfokus pada dokumen penelitian biomedis panjang (lebih dari 6 halaman), terdiri dari 7.569 entri dengan tiga label kelas utama:

- Thyroid_Cancer: Publikasi yang berkaitan dengan penelitian kanker tiroid (2.810 sampel).
- Colon_Cancer: Publikasi yang berkaitan dengan penelitian kanker usus besar (2.579 sampel).
- Lung_Cancer: Publikasi yang berkaitan dengan penelitian kanker paru-paru (2.180 sampel).

Setiap entri berisi teks lengkap dari publikasi penelitian biomedis. Tujuan dari dataset ini adalah untuk mengklasifikasikan dokumen berdasarkan fokus utama jenis kanker.

Link Kaggle :
https://www.kaggle.com/datasets/falgunipatel19/biomedical-text-publication-classification/data

https://cancercare-ai.streamlit.app

EXPLORATORY DATA ANALYSIS (EDA)

1. CLASS DISTRIBUTION

- Thyroid_Cancer: 2.810 dokumen (37,1% dari total)
- Colon_Cancer: 2.580 dokumen (34,1% dari total)
- Lung_Cancer: 2.180 dokumen (28,8% dari total)

Target	
Thyroid_Cancer	2810
Colon_Cancer	2580
Lung_Cancer	2180

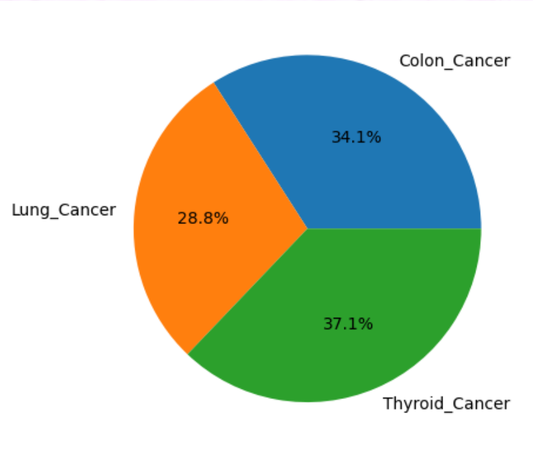

2. KERNEL DISTRIBUTION OF NUMBER OF WORDS

Grafik menunjukkan bahwa dokumen pada kategori Thyroid_Cancer dan Colon_Cancer umumnya memiliki panjang yang seragam, berkisar antara 4.000 hingga 4.800 kata. Sementara itu, kategori Lung_Cancer memiliki distribusi bimodal, dengan dua puncak utama di sekitar 1.000 kata dan 4.000 kata, yang menunjukkan variasi panjang dokumen yang lebih besar. Pola ini mengindikasikan bahwa dokumen kanker paru-paru terdiri dari kombinasi artikel pendek dan panjang, berbeda dengan dua kategori lainnya yang lebih konsisten dalam panjang teks.

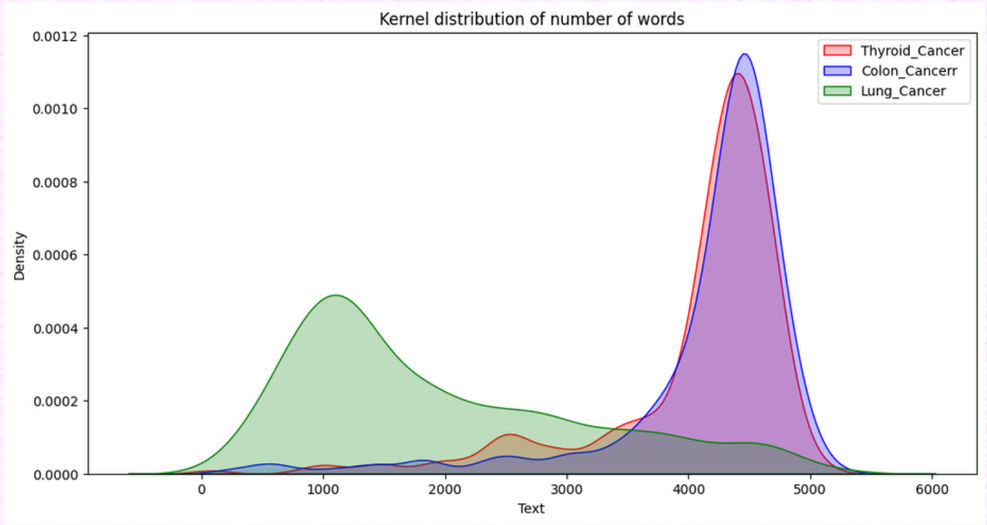

https://cancercare-ai.streamlit.app

EXPLORATORY DATA ANALYSIS (EDA)

3. WORLDCLOUD

A. WORDCLOUD FOR THYROID CANCER

Visualisasi WordCloud ini menggambarkan kata-kata yang paling sering muncul dalam dokumen terkait kanker tiroid. Kata-kata seperti "patient", "used", "cancer", "associated", "study", dan "found" muncul paling dominan, menunjukkan fokus utama pada studi klinis terhadap pasien, penggunaan metode tertentu, dan hasil-hasil penelitian yang menunjukkan hubungan atau temuan signifikan terkait kanker Tiroid

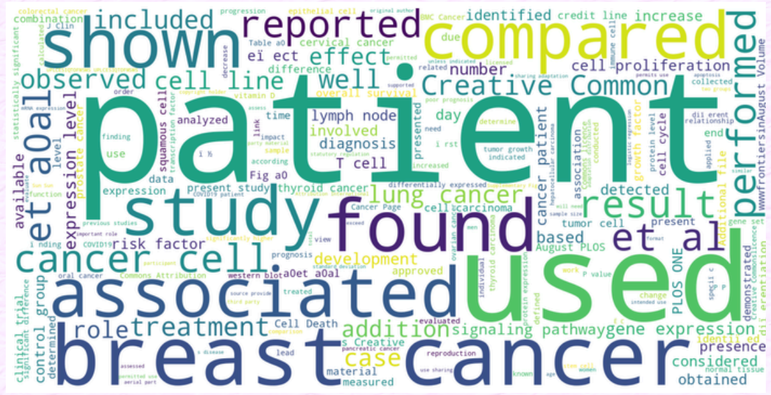

B. WORDCLOUD FOR COLON CANCER

Visualisasi WordCloud untuk Colon Cancer menunjukkan kata-kata yang paling sering muncul dalam publikasi terkait penyakit ini. Kata-kata dominan seperti "patient", "cancer", "used", "associated", dan "found" mengindikasikan fokus utama penelitian, yaitu pada pasien, penggunaan metode tertentu, serta hubungan dan temuan signifikan terkait kanker kolon.

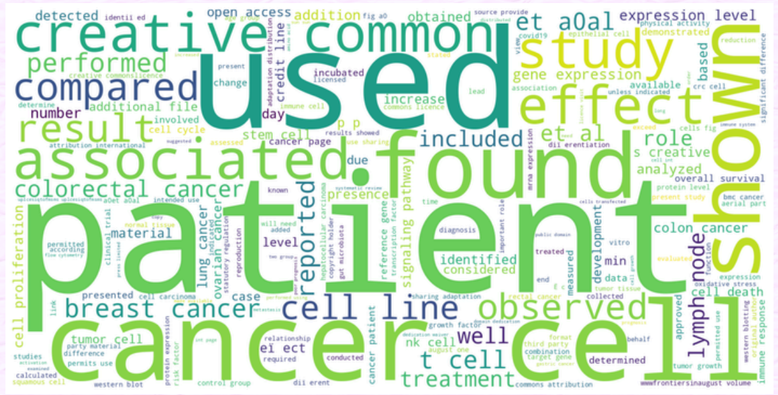

C. WORDCLOUD FOR LUNG CANCER

WordCloud untuk Lung Cancer menampilkan kata-kata kunci yang paling sering digunakan dalam penelitian terkait kanker paru-paru. Kata-kata seperti "patient", "cancer", "lung", "cell", dan "study" muncul paling dominan, menunjukkan fokus utama pada studi klinis terhadap pasien dan analisis sel kanker paru-paru

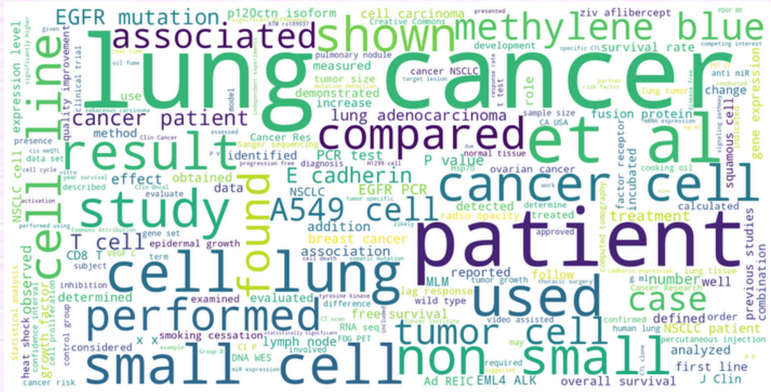

https://cancercare-ai.streamlit.app

PREPROCESSING

1. TEXT PREPROCESSING

- Bersihkan Teks: Menghapus karakter non-huruf seperti angka, tanda baca, dan simbol agar teks hanya berisi huruf dan spasi.
- Hilangkan Stopword: Menghapus kata-kata umum dalam bahasa Inggris yang tidak memiliki makna penting (seperti "and", "the", "with"), termasuk nama label kanker agar tidak memengaruhi hasil klasifikasi.
- Ubah ke Huruf Kecil: Semua kata diubah menjadi huruf kecil untuk menjaga konsistensi dalam analisis teks.
- Tokenisasi Kata: Memecah setiap kalimat menjadi daftar kata-kata (token) sebagai langkah awal sebelum vektorisasi.

```
def clean_text(d):
    pattern = r'[^a-zA-Z\s]'
    text = re.sub(pattern, '', d)
    return text

names = ['Colon_Cancer', 'Lung_Cancer', 'Thyroid_Cancer']

def clean_stopword(d):
    stop_words = stopwords.words('english')
    for name in names:
        stop_words.append(name)
    return " ".join([w.lower() for w in d.split() if w.lower() not in stop_words and len(w) > 1])

def tokenize(d):
    return word_tokenize(d)

df['final_text']= df.Text.apply(clean_text).apply(clean_stopword).apply(tokenize)
df.head()
```

```
for i in range(len(df)):
    df.loc[i, 'final_text'] = " ".join(df.loc[i, 'final_text'])

df['Target']= df['Target'].replace(['Thyroid_Cancer', 'Colon_Cancer', 'Lung_Cancer'],[0,1,2])
df
```

2. LABEL ENCODING

- Gabung Token: Menggabungkan kembali token menjadi satu string teks utuh.
- Ubah Label ke Angka: Mengonversi label kanker dari teks ke angka (Thyroid: 0, Colon: 1, Lung: 2).

https://cancercare-ai.streamlit.app

MODEL DEVELOPMENT & EVALUATION

```
X = df.final_text
y = df.Target
X_train, X_test, y_train, y_test = train_test_split(X, y, test_size = 0.2, random_state = 4)

def tfidf(words):
    tfidf_vectorizer = TfidfVectorizer()
    data_feature = tfidf_vectorizer.fit_transform(words)
    return data_feature, tfidf_vectorizer

X_train_tfidf, tfidf_vectorizer = tfidf(X_train.tolist())
X_test_tfidf = tfidf_vectorizer.transform(X_test.tolist())
```

1. TF-IDF

Pada tahap ini, dilakukan proses vektorisasi teks menggunakan metode TF-IDF (Term Frequency-Inverse Document Frequency) untuk mengubah data teks menjadi representasi numerik yang dapat dipahami oleh model machine learning. Dataset terlebih dahulu dibagi menjadi data latih dan data uji, lalu fitur dari teks diekstraksi berdasarkan frekuensi dan pentingnya kata dalam dokumen. Hasil vektorisasi ini digunakan sebagai input bagi model klasifikasi.

2. LOGISTIC REGRESSION

Pada tahap ini digunakan algoritma Logistic Regression untuk membangun model klasifikasi terhadap jenis kanker berdasarkan teks. Model dilatih menggunakan data hasil ekstraksi fitur dari TF-IDF dan kemudian diuji untuk memprediksi label kanker. Evaluasi dilakukan menggunakan metrik akurasi, presisi, dan recall untuk mengetahui sejauh mana model mampu mengklasifikasikan data dengan benar.

```
lr_tfidf = LogisticRegression(random_state=42,solver = 'liblinear')
lr_tfidf.fit(X_train_tfidf, y_train)
y_predicted_lr = lr_tfidf.predict(X_test_tfidf)

def score_metrics(y_test, y_predicted):
    accuracy = accuracy_score(y_test, y_predicted)
    precision = precision_score(y_test, y_predicted,average= 'macro')
    recall = recall_score(y_test, y_predicted,average='macro')
    print("accuracy = %0.3f, precision = %0.3f, recall = %0.3f" % (accuracy, precision, recall))

score_metrics(y_test, y_predicted_lr)
```

https://cancercare-ai.streamlit.app

MODEL DEVELOPMENT & EVALUATION

```
accuracy = 0.954, precision = 0.957, recall = 0.957
```

Berdasarkan hasil evaluasi model Logistic Regression, diperoleh akurasi sebesar 95,4%, yang berarti mayoritas prediksi model sesuai dengan label aslinya. Selain itu, nilai presisi dan recall yang sama tinggi (95,7%) menunjukkan bahwa model mampu mengenali setiap jenis kanker dengan baik dan konsisten, serta minim kesalahan dalam klasifikasi. Hal ini menunjukkan bahwa model memiliki performa yang stabil dan andal dalam membedakan antara kanker tiroid, kolon, dan paru-paru berdasarkan data teks.

3. CONFUSION MATRIX

- Thyroid_Cancer: 504 data diklasifikasikan benar, 30 salah sebagai Colon_Cancer.
- Colon_Cancer: 510 data diklasifikasikan benar, 40 salah sebagai Thyroid_Cancer.
- Lung_Cancer: Seluruh 430 data diklasifikasikan dengan benar, tanpa kesalahan.

Kesimpulan: Model sangat akurat dalam mendeteksi Lung_Cancer dan cukup baik dalam membedakan antara Colon dan Thyroid meskipun ada sedikit kesalahan klasifikasi di antara keduanya.

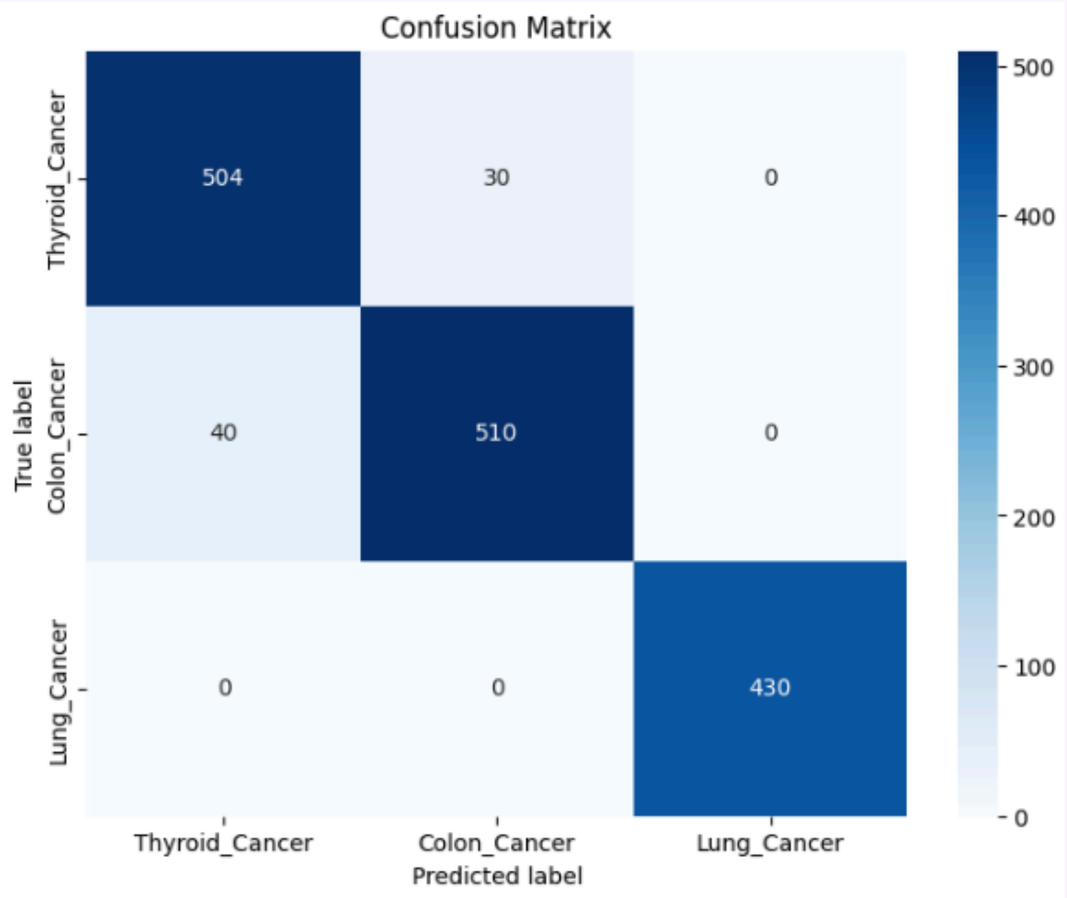

https://cancercare-ai.streamlit.app

CUSTOM PREDICTION

1. DEFINE A PREDICTION FUNCTION

Kode ini digunakan untuk memprediksi jenis kanker dari teks medis. Teks dibersihkan dan diproses oleh preprocess_text, lalu diubah menjadi vektor dengan TF-IDF dan diprediksi jenis kankernya oleh model lr_tfidf. Hasil prediksi dikembalikan dalam bentuk label seperti Thyroid Cancer, Colon Cancer, atau Lung Cancer.

```python
def preprocess_text(text):
    pattern = r'[^a-zA-Z\s]'
    text = re.sub(pattern, '', text)

    stop_words = stopwords.words('english')
    for name in names:
        stop_words.append(name)

    text_clean = " ".join([w.lower() for w in text.split() if w.lower() not in stop_words and len(w) > 1])
    text_tokens = word_tokenize(text_clean)
    return " ".join(text_tokens)

def predict_cancer(text):
    processed_text = preprocess_text(text)
    vectorized_text = tfidf_vectorizer.transform([processed_text])
    prediction = lr_tfidf.predict(vectorized_text)[0]

    label_map = {0: 'Thyroid_Cancer', 1: 'Colon_Cancer', 2: 'Lung_Cancer'}
    return label_map[prediction]
```

2. DEFINE A PREDICTION FUNCTION

Kode ini memungkinkan pengguna memasukkan teks untuk diprediksi jenis kankernya secara interaktif. Program akan terus berjalan hingga pengguna mengetik "exit", lalu menampilkan hasil prediksi setiap kali teks dimasukkan.

```python
while True:
    print("\n=== Prediksi Kanker dari Teks ===")
    user_input = input("Masukkan teks untuk diprediksi (atau ketik 'exit' untuk keluar):\n> ")

    if user_input.lower() == 'exit':
        print("Terima kasih! Program selesai.")
        break

    prediction_result = predict_cancer(user_input)
    print(f"✅ Hasil Prediksi: {prediction_result}")
```

```
=== Prediksi Kanker dari Teks ===
Masukkan teks untuk diprediksi (atau ketik 'exit' untuk keluar):
> The presence of papillary carcinoma in the thyroid gland was detected through ultrasound imaging and confirmed by fine needle aspiration.
✅ Hasil Prediksi: Thyroid_Cancer

=== Prediksi Kanker dari Teks ===
Masukkan teks untuk diprediksi (atau ketik 'exit' untuk keluar):
> Biopsy of the colon revealed abnormal growth in the mucosal lining, indicating the progression of adenocarcinoma in the large intestine.
✅ Hasil Prediksi: Colon_Cancer

=== Prediksi Kanker dari Teks ===
Masukkan teks untuk diprediksi (atau ketik 'exit' untuk keluar):
> CT scans showed multiple nodules in the lung, and gene expression analysis confirmed the presence of non-small cell lung carcinoma.
✅ Hasil Prediksi: Lung_Cancer

=== Prediksi Kanker dari Teks ===
Masukkan teks untuk diprediksi (atau ketik 'exit' untuk keluar):
> exit
Terima kasih! Program selesai.
```

https://cancercare-ai.streamlit.app

SAVE MODEL

```
joblib.dump(lr_tfidf, 'model.pkl')
joblib.dump(tfidf_vectorizer, 'vectorizer.pkl')
```

Pada tahap ini, model Logistic Regression dan TF-IDF vectorizer yang telah dilatih disimpan menggunakan joblib dalam bentuk file model.pkl dan vectorizer.pkl. Penyimpanan ini bertujuan agar model tidak perlu dilatih ulang setiap kali ingin digunakan, sehingga proses deployment menjadi lebih efisien. Setelah kedua file ini diunduh, keduanya dapat langsung dimanfaatkan untuk membangun aplikasi prediksi berbasis teks yaitu CancerCare AI yang dapat mengklasifikasikan jenis kanker berdasarkan deskripsi teks medis secara cepat dan akurat. Langkah ini merupakan jembatan penting dari eksperimen ke implementasi nyata.

https://cancercare-ai.streamlit.app

KESIMPULAN

CancerCare AI berhasil dikembangkan sebagai solusi awal berbasis machine learning untuk mengklasifikasikan jenis kanker melalui analisis teks medis. Proyek ini menggunakan algoritma Logistic Regression karena kesederhanaannya, efisiensinya dalam menangani data teks, serta kemampuannya memberikan hasil prediksi yang sangat baik—terbukti dari akurasi yang tinggi dan kesalahan klasifikasi yang minim. Dengan dukungan teknik TF-IDF dalam ekstraksi fitur, model mampu memahami konteks penting dari setiap deskripsi. Model yang telah dilatih dan disimpan kemudian siap diimplementasikan ke dalam aplikasi berbasis Streamlit, sehingga memungkinkan pengguna untuk secara langsung melakukan prediksi jenis kanker secara cepat, mudah, dan akurat melalui antarmuka yang interaktif.

https://cancercare-ai.streamlit.app

OUR TEAM

ANGELA N. O. R

FAHRI S. H

M. NUGI R

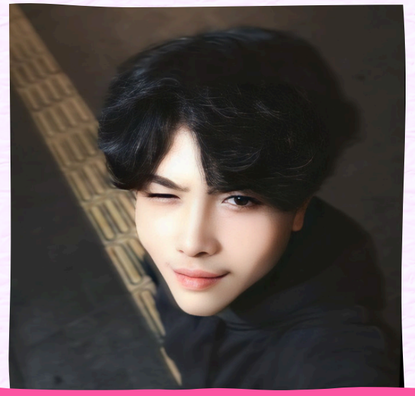

Z. K. R. TYO

https://cancercare-ai.streamlit.app

THANK YOU

Visit Our Colab

https://colab.research.google.com

Visit Our Github

https://github.com/NugiR/CancerCare_AI

Visit Our Website

https://cancercare-ai.streamlit.app